Пункт 5. Как доказать эффект внедрения «Радара»

Версия по официальному кейсу, уточнение 12.11.2026. Все целевые пороги ниже - предложение для согласования до пилота, не уже полученные результаты. Исходные факты: около 40 менеджеров поддержки, единая база, история за год. Периодичность ручного анализа пока неизвестна.

1. Что считаем успехом

Главный эффект: больше повторяющихся некритичных потребностей попадает в поле зрения продуктовой команды при меньших трудозатратах подготовки. Отсутствие релиза и статистического всплеска не исключает тему из анализа. Качество не сводится к числу созданных задач: поток бесполезных задач ухудшает процесс.

Основные метрики:

Метрика	Формула и единица	Источник	Запасной способ
Полнота тем	Найденные эталонные повторяющиеся темы / все эталонные темы	Независимая разметка отложенного периода; повторы: ≥3 разных автора в 28 дней	Ручной двухэкспертный разбор стратифицированной выборки с весами каналов
Полезность карточек	Карточки с верной потребностью, группировкой и адресатом / проверенные карточки	Оценки продуктовой команды с причинами отклонения	Слепое попарное сравнение ручной и автоматической сводки, без указания автора
Задержка передачи	delivered_at − eligible_at, медиана и p90 в рабочих часах	eligible_at - время третьего уникального автора; delivered_at - подтверждение доставки	Если delivered_at нет: presented_at в интерфейсе; назвать замену, не смешивать серии
Трудозатраты	Сумма минут выгрузки, анализа, подготовки, проверки и исправлений за цикл	Хронометраж по ролям до/после, вместе с объёмом и составом потока	Выборочные дневники + наблюдение за одинаковым заданием; интервью только как предварительная оценка
Покрытие обработки	Успешно обработанные тикеты / все доступные тикеты, отдельно по каналу	Счётчики импорта и статусов, cursor исходной системы	Сверка суточных выгрузок по ID; необработанное остаётся в знаменателе

Метрика	Формула и единица	Источник	Запасной способ
Дополнительная нагрузка поддержки	Новые минуты поддержки на 100 обращений	Хронометраж действий, введённых Радаром	Дневник и наблюдение в пилоте

Дополнительные: доля утверждений с подтверждающими источниками; ошибочные слияния и дробления тем; доля карточек, уже существующих в трекере; время до решения команды; доля повторяющихся вопросов после внедрения изменения. «Не приняли в разработку» не всегда означает ошибку агента: правильная потребность может проиграть приоритизацию. Для precision оцениваем корректность и релевантность, бизнес-решение фиксируем отдельно.

2. Ретроспектива

1. Согласовать продукты, роли доступа и словарь типов потребностей. Выбрать 3-5 продуктов с разными каналами и объёмом, включая «Вебнефть».

2. Выгрузить минимум 8-12 недель истории с ID, продуктом, временем, автором-псевдонимом, каналом, статусом. Отдельно описать недоступные записи и вложения. Доступная история до года нужна для сезонности, но не вся отправляется в контекст модели.

3. Сверить полноту выгрузки с исходной системой. Удалить транспортные дубли; обращения одного автора сохранить для истории, но считать уникального автора один раз в теме.

4. Два эксперта независимо размечают тип, тему, продукт, направление пожелания и основания. Разногласия разрешает третий. Сохранить инструкцию разметки, долю согласия и спорные примеры.

5. Разделить настройку и проверку по времени; повторяющиеся шаблоны не должны протекать между выборками. Часть продуктов оставить вне настройки для проверки переноса. Заморозить промпт, версию модели, окна и пороги до финального прогона.

6. Восстановить исторический момент накопления темы, сопоставить с датой первого появления в трекере/протоколе команды. Если следов передачи нет, задержка прошлого процесса неизвестна: не заменять её предположением «2-5 дней».

7. Провести контролируемый ручной разбор того же обезличенного пакета. Измерить операции секундомером, не просить людей оценивать «на глаз» весь прошлый год.

3. Пилот и причинность

Сначала две недели теневого режима: агент не создаёт задачи, продуктовые эксперты оценивают сводки. Затем 2-4 недели ограниченного внедрения с тем же расписанием. По возможности продукты включаются ступенчато: ещё не подключённые служат сравнением. Сравниваем изменения до/после в подключённой группе с изменениями в контрольной, учитывая загрузку, канал, релизы и сезонность. При слишком малой выборке называем результат наблюдением, а не доказанным причинным эффектом.

Поддержка продолжает обычную работу, без обязательной новой кнопки на каждом тикете. На разбор сводки назначается представитель продуктовой команды. Его время обязательно вычитается из выигрыша. Сокращение повторных обращений измеряем после реального изменения продукта, а не сразу после установки агента.

Заранее фиксируем: список продуктов, период, правила повторов, объём выборки, допустимые исключения, целевые пороги и дату решения. Если качество не прошло, исправляем на новой обучающей части и получаем новую отложенную выборку; повторный просмотр прежнего финала не называем слепой проверкой.

4. Цели и решение о запуске

До пилота согласуем критерии: precision полезных карточек с доверительным интервалом на ≥100 карточках, recall повторяющихся тем, подтверждённость источниками и снижение времени подготовки при сохранении качества. Пороги определяем с заказчиком по исходному процессу и допустимым ошибкам; работу поддержки учитываем в хронометраже. При 100 карточках показываем интервал Уилсона, а не только точечный процент.

Задержку передачи сравниваем с измеренным baseline; заранее не обещаем ускорение в 10 раз. При еженедельной сводке честная задержка может быть до недели: SLO обработки отдельного тикета и периодичность информирования команды - разные вещи. При высокой ценности темы допускается отдельное согласованное уведомление.

Отказные ворота: утечка данных между продуктами, выполнение запрещённого действия, необъяснимое исчезновение тикетов, невосстановимое состояние, неприемлемое качество ASR/VL/NER. Нулевое число ошибок в тесте не доказывает абсолютную безопасность; указываем число сценариев, каналов и границы проверки.

Go: цели достигнуты, продуктовая команда подтверждает полезность, фактические часы дают положительный эффект, есть ответственные за доступы и эксплуатацию. Ограниченный Go: работает только проверенный продукт/канал, остальные не считаются покрытыми. No-Go: качество или экономический предел ниже стоимости реализации заказчика; сравнить с простой выгрузкой без LLM.

5. Наблюдение после запуска

Еженедельно: объём и возраст очередей, ошибки по каналам, карточки и решения, непокрытые темы, подозрительные пачки, новые затраты времени. Ежемесячно: независимая выборочная разметка, precision/recall с интервалами, дрейф словаря, денежная реализуемость высвобожденного времени. После смены модели или промпта - повторная приёмка и возможность отката версии.

Минимальный журнал событий: ticket_imported, content_extracted, analysis_completed/failed, theme_eligible, digest_queued, digest_delivered, decision_recorded, change_implemented. Сохраняются product_id, обезличенные ID, время и версия компонента; исходные персональные данные в журнал не попадают. Удаление по сроку хранения распространяется на производные данные и резервные копии по политике компании.

6. Как метрики становятся деньгами

По каждой роли: (часы до − часы после) × полная стоимость часа. Складываем без двойного учёта; показанные отдельно часы операторов и аналитиков должны относиться к разным операциям. Эффект по всем 40 сотрудникам нельзя предполагать, пока не известно, сколько из них участвует в ручном анализе.

Стоимость высвобождённого времени отдельно от денег. Для денежного потока необходим подтверждённый механизм: меньше оплаченных переработок, сокращение расходов подрядчика, предотвращённый найм. Если сотрудников просто перераспределили, показываем рост мощности процесса; не называем это снижением фонда оплаты труда. Коэффициент денежной реализации k подтверждает владелец бюджета.

Финансовая модель получает измеренные часы, ставки, освоение по годам и k. До измерений остаются сценарии. Доход от улучшения продукта добавляется только при отдельном обосновании причинности и отсутствии пересечения с уже посчитанной экономией.

7. Три сценария экономии в неделю на одного сотрудника

1,5 / 3 / 6 ч/нед. на сотрудника - чувствительность, не замер и не измеренный минимум. Охват всех 40 сотрудников и чистую экономию с проверкой и исправлениями подтверждают хронометражем.

Общие вводные

Из условия «Газпром нефть» взяты около 40 сотрудников и бесплатная инфраструктура. Остальное - допущения из [data/economics.json](../data/economics.json), `base.inputs`:

Вводная	Значение и смысл
`staff`	40 сотрудников
`weeks`	48 рабочих недель в год
`hourly_cost`	800 руб./ч, оценка полной стоимости часа
`cash_share`	25% стоимости времени допускается реализовать деньгами
`adoption`	50% / 100% / 100% освоения в годы 1 / 2 / 3
`discount`	20% в год
Горизонт	3 года, по числу элементов `adoption`
`wage_growth`	0%, ставка часа не растёт

Меняется только `weekly_saved_hours`. Бесплатная инфраструктура не делает бесплатным труд внедрения и эксплуатации. Их расходы неизвестны; это не полная стоимость владения.

Часы и стоимость времени

Для экономии `s` ч/нед. на сотрудника: `H=40 × 48 × s`, ч команды/год; `V=H × 800`, руб./год стоимости высвобождённого времени.

Экономия на одного сотрудника, ч/нед.	H, ч команды/год	V, руб./год
1,5	2 880	2 304 000
3	5 760	4 608 000
6	11 520	9 216 000

H и V даны при полном освоении; в первом году доступны 50%. V - стоимость мощности, не снижение зарплат. При условных 0,5 ч после нужны 2 / 3,5 / 6,5 ч до. **6 ч экономии требуют 6,5 ч исходной работы**. До/после неизвестны, в расчёте используется экономия s.

Дисконтированный денежный эффект за 3 года

Деньги требуют снижения оплаченных переработок, расходов подрядчика или предотвращённого найма. Условную `cash_share=25%` подтверждает владелец бюджета; перераспределение времени денег не даёт. PV - приведённая стоимость предполагаемого реализуемого денежного эффекта до вычета внедрения и эксплуатации, отдельно от V.

При потоках в конце года и нулевом росте ставки:

- `CF_t = V × 0,25 × adoption_t`, руб./год.

- `PV = CF_1 / 1,2 + CF_2 / 1,2² + CF_3 / 1,2³`, руб. на начало проекта.

Экономия, ч/нед. на сотрудника	CF год 1, руб.	CF год 2, руб.	CF год 3, руб.	Денежный эффект PV за 3 года, руб.
1,5	288 000	576 000	576 000	973 333,33
3	576 000	1 152 000	1 152 000	1 946 666,67
6	1 152 000	2 304 000	2 304 000	3 893 333,33

Для базы: `H=40 × 48 × 1,5=2880`; `V=2880 × 800=2304000`; `CF_1=V × 0,25 × 0,5=288000`; `CF_2=CF_3=576000`. Подстановка в PV даёт 973333,33 руб. При 3 и 6 ч часы и потоки в 2 и 4 раза больше; округляется лишь итоговый PV до копеек.

Отдельный вывод: предел первоначальных вложений

Для вложений I на начало проекта и дополнительных расходов года O_t: `NPV = −I + Σ (CF_t − O_t)/(1+d)^t`. При NPV=0: `Imax,d = PV − Σ O_t/(1+d)^t`; при O_t=0: `Imax,d=PV`. Без дисконта `Imax=CF_1+CF_2+CF_3`, в базе 1440000 руб.

Предел совпадает с PV только без иных дополнительных затрат. Это граница разовых вложений, не гарантированная экономия, выручка или утверждённый бюджет. Подтверждённое сопровождение вычитают по приведённой стоимости; сейчас оно неизвестно. При `cash_share=0` все потоки, денежный эффект и предел равны нулю во всех сценариях, хотя H и V положительны.

Воспроизводимость и прежние полные сценарии

Результаты: [data/economics-weekly.json](../data/economics-weekly.json). Генератор [scripts/build_weekly_scenarios.py](../scripts/build_weekly_scenarios.py) читает `data/economics.json#/base/inputs`. Из корня проекта:

```sh
python3 -B scripts/build_weekly_scenarios.py

python3 -B scripts/build_weekly_scenarios.py --check

python3 -B -m unittest discover -s tests -p test_economics_weekly.py -v
```

`-B` запрещает байткод. Генератор воспроизводит JSON; `--check` без записи выявляет отсутствие, повреждение и расхождение. `unittest discover` запускает тесты: `-s` каталог, `-p` файл, `-v` подробности.

Полные `conservative/base/optimistic` сохранены в `data/economics.json`: там меняются несколько вводных. Старый `optimistic`: 2,5 ч/нед., 1000 руб./ч, денежная доля 50%, дисконт 10%, а не новая строка 6 ч/нед. Серии не суммируются.

8. Уточнение нагрузки от 12.11.2026

По уточнению организаторов, переданному 12.11.2026: 480 обращений/день суммарно по 40 продуктам, не на каждый. Прямого нового PDF и URL нет; это не реальный замер или пилот. Provenance: `user_report_of_organizer_case_update`, дата `2026-11-12`; дословное сообщение в JSON.

В первоначальном условии около 40 менеджеров - численность поддержки, другой показатель. `480/40=12` в день на продукт - среднее, не пик; распределение неравномерно, профиль неизвестен.

Допущение	Расчёт	Результат
48 недель × 5 рабочих дней	480 × 240	115200 обращений/год
8 часов в рабочем дне	480/8	60 обращений/час всего
Среднее по 40 продуктам	60/40	1,5 обращения/час на продукт

Это пересчёт условия, не наблюдённый годовой объём или пик. Прежние 1200/1800/3600 - расчётная ёмкость из численности и допущений; активная нагрузка v14 - 480/день.

Мощность текстового пути

Допущения: пик 5×, 8 ч = 28800 с, один полный текстовый путь на новое обращение, включая вызовы моделей и программные этапы. `slots = ceil(N × peak × seconds / 28800)`.

Полный путь, с (допущение)	Расчёт при N=480, peak=5	Слоты
15	ceil(480 × 5 × 15 / 28800)	2
30	ceil(480 × 5 × 30 / 28800)	3
60	ceil(480 × 5 × 60 / 28800)	5

Это расчёт параллельности при допущениях: параллельные пути, не GPU или измеренная скорость моделей. ASR/VL, повторы, p95, контекст и восстановление очереди проверяются отдельно. Замеры на 800/1500/3000 не подтверждают качество при 480. Сохранённые метрики v5c относятся к своему контрольному набору.

Потенциал автоответа отдельно от PV

`H_auto = N × D × r × s × t / 60`, ч/год. N=480/день; D=240 дней/год - допущение; r - доля повторов; s - допуск среди повторов; t - чистая экономия минут на допустимый случай. r, s и t неизвестны; их измеряют на данных компании. Precision/Recall синтетики не являются s.

Иллюстрация: r=20%, s=50%, t=3,5 мин; `480 × 240 × 0,2 × 0,5 × 3,5 / 60 = 672 ч/год`. Это допущения, не результат ML или пилота. Доставка не подключена; денежная реализация и отсутствие двойного счёта не доказаны. К базовому PV часы не прибавлены. N не входит в `H=40 × 48 × weekly_saved_hours`; PV 0,973/1,947/3,893 млн руб. не меняются.

Источник: [data/case-load-20261112.json](../data/case-load-20261112.json). Генератор: `python3 -B scripts/build_case_load_v14.py`; проверка без записи: добавить `--check`. Тесты: `python3 -B -m unittest discover -s tests -p test_case_load_v14.py -v`.