Пункт 5. Как доказать эффект внедрения «Радара»

Версия по официальному кейсу, 01.11.2026. Все целевые пороги ниже - предложение для согласования до пилота, не уже полученные результаты. Исходные факты: около 40 менеджеров поддержки, единая база, история за год. Периодичность ручного анализа пока неизвестна.

1. Что считаем успехом

Главный эффект: больше повторяющихся некритичных потребностей попадает в поле зрения продуктовой команды при меньших трудозатратах подготовки. Отсутствие релиза и статистического всплеска не исключает тему из анализа. Качество не сводится к числу созданных задач: поток бесполезных задач ухудшает процесс.

Основные метрики:

Метрика	Формула и единица	Источник	Запасной способ
Полнота тем	Найденные эталонные повторяющиеся темы / все эталонные темы	Независимая разметка отложенного периода; повторы: ≥3 разных автора в 28 дней	Ручной двухэкспертный разбор стратифицированной выборки с весами каналов
Полезность карточек	Карточки с верной потребностью, группировкой и адресатом / проверенные карточки	Оценки продуктовой команды с причинами отклонения	Слепое попарное сравнение ручной и автоматической сводки, без указания автора
Задержка передачи	delivered_at − eligible_at, медиана и p90 в рабочих часах	eligible_at - время третьего уникального автора; delivered_at - подтверждение доставки	Если delivered_at нет: presented_at в интерфейсе; назвать замену, не смешивать серии
Трудозатраты	Сумма минут выгрузки, анализа, подготовки, проверки и исправлений за цикл	Хронометраж по ролям до/после, вместе с объёмом и составом потока	Выборочные дневники + наблюдение за одинаковым заданием; интервью только как предварительная оценка
Покрытие обработки	Успешно обработанные тикеты / все доступные тикеты, отдельно по каналу	Счётчики импорта и статусов, cursor исходной системы	Сверка суточных выгрузок по ID; необработанное остаётся в знаменателе

Метрика	Формула и единица	Источник	Запасной способ
Дополнительная нагрузка поддержки	Новые минуты поддержки на 100 обращений	Хронометраж действий, введённых Радаром	Дневник и наблюдение в пилоте

Дополнительные: доля утверждений с подтверждающими источниками; ошибочные слияния и дробления тем; доля карточек, уже существующих в трекере; время до решения команды; доля повторяющихся вопросов после внедрения изменения. «Не приняли в разработку» не всегда означает ошибку агента: правильная потребность может проиграть приоритизацию. Для precision оцениваем корректность и релевантность, бизнес-решение фиксируем отдельно.

2. Ретроспектива

1. Согласовать продукты, роли доступа и словарь типов потребностей. Выбрать 3-5 продуктов с разными каналами и объёмом, включая «Вебнефть».

2. Выгрузить минимум 8-12 недель истории с ID, продуктом, временем, автором-псевдонимом, каналом, статусом. Отдельно описать недоступные записи и вложения. Доступная история до года нужна для сезонности, но не вся отправляется в контекст модели.

3. Сверить полноту выгрузки с исходной системой. Удалить транспортные дубли; обращения одного автора сохранить для истории, но считать уникального автора один раз в теме.

4. Два эксперта независимо размечают тип, тему, продукт, направление пожелания и основания. Разногласия разрешает третий. Сохранить инструкцию разметки, долю согласия и спорные примеры.

5. Разделить настройку и проверку по времени; повторяющиеся шаблоны не должны протекать между выборками. Часть продуктов оставить вне настройки для проверки переноса. Заморозить промпт, версию модели, окна и пороги до финального прогона.

6. Восстановить исторический момент накопления темы, сопоставить с датой первого появления в трекере/протоколе команды. Если следов передачи нет, задержка прошлого процесса неизвестна: не заменять её предположением «2-5 дней».

7. Провести контролируемый ручной разбор того же обезличенного пакета. Измерить операции секундомером, не просить людей оценивать «на глаз» весь прошлый год.

3. Пилот и причинность

Сначала две недели теневого режима: агент не создаёт задачи, продуктовые эксперты оценивают сводки. Затем 2-4 недели ограниченного внедрения с тем же расписанием. По возможности продукты включаются ступенчато: ещё не подключённые служат сравнением. Сравниваем изменения до/после в подключённой группе с изменениями в контрольной, учитывая загрузку, канал, релизы и сезонность. При слишком малой выборке называем результат наблюдением, а не доказанным причинным эффектом.

Поддержка продолжает обычную работу, без обязательной новой кнопки на каждом тикете. На разбор сводки назначается представитель продуктовой команды. Его время обязательно вычитается из выигрыша. Сокращение повторных обращений измеряем после реального изменения продукта, а не сразу после установки агента.

Заранее фиксируем: список продуктов, период, правила повторов, объём выборки, допустимые исключения, целевые пороги и дату решения. Если качество не прошло, исправляем на новой обучающей части и получаем новую отложенную выборку; повторный просмотр прежнего финала не называем слепой проверкой.

4. Цели и решение о запуске

Предложенные цели: precision полезных карточек ≥85%, нижняя 95%-граница ≥75% на ≥100 карточках; recall эталонных повторяющихся тем ≥80%; подтверждённость утверждений ≥95%; не менее 30% снижения времени подготовки при неухудшении качества; дополнительная обязательная работа поддержки на тикет отсутствует. При 100 карточках показываем интервал Уилсона, а не только точечный процент.

Задержку передачи сравниваем с измеренным baseline; заранее не обещаем ускорение в 10 раз. При еженедельной сводке честная задержка может быть до недели: SLO обработки отдельного тикета и периодичность информирования команды - разные вещи. При высокой ценности темы допускается отдельное согласованное уведомление.

Отказные ворота: утечка данных между продуктами, выполнение запрещённого действия, необъяснимое исчезновение тикетов, невосстановимое состояние, неприемлемое качество ASR/VL/NER. Нулевое число ошибок в тесте не доказывает абсолютную безопасность; указываем число сценариев, каналов и границы проверки.

Go: цели достигнуты, продуктовая команда подтверждает полезность, фактические часы дают положительный эффект, есть ответственные за доступы и эксплуатацию. Ограниченный Go: работает только проверенный продукт/канал, остальные не считаются покрытыми. No-Go: качество или экономический предел ниже стоимости реализации заказчика; сравнить с простой выгрузкой без LLM.

5. Наблюдение после запуска

Еженедельно: объём и возраст очередей, ошибки по каналам, карточки и решения, непокрытые темы, подозрительные пачки, новые затраты времени. Ежемесячно: независимая выборочная разметка, precision/recall с интервалами, дрейф словаря, денежная реализуемость высвобожденного времени. После смены модели или промпта - повторная приёмка и возможность отката версии.

Минимальный журнал событий: ticket_imported, content_extracted, analysis_completed/failed, theme_eligible, digest_queued, digest_delivered, decision_recorded, change_implemented. Сохраняются product_id, обезличенные ID, время и версия компонента; исходные персональные данные в журнал не попадают. Удаление по сроку хранения распространяется на производные данные и резервные копии по политике компании.

6. Как метрики становятся деньгами

По каждой роли: (часы до − часы после) × полная стоимость часа. Складываем без двойного учёта; показанные отдельно часы операторов и аналитиков должны относиться к разным операциям. Эффект по всем 40 сотрудникам нельзя предполагать, пока не известно, сколько из них участвует в ручном анализе.

Стоимость высвобождённого времени отдельно от денег. Для денежного потока необходим подтверждённый механизм: меньше оплаченных переработок, сокращение расходов подрядчика, предотвращённый найм. Если сотрудников просто перераспределили, показываем рост мощности процесса; не называем это снижением фонда оплаты труда. Коэффициент денежной реализации k подтверждает владелец бюджета.

Финансовая модель получает измеренные часы, ставки, освоение по годам и k. До измерений остаются сценарии. Доход от улучшения продукта добавляется только при отдельном обосновании причинности и отсутствии пересечения с уже посчитанной экономией.